



Plateforme nationale de prédiction des ruptures de médicaments · Tunisie

Documentation technique

Architecture, modèles, API et sécurité

Version 1.0 · Juillet 2026

github.com/Ahmed-Yassine-10/Nabbahni


Aide à la décision — validation humaine obligatoire

1. Problème et positionnement


Une rupture de médicament se constate aujourd'hui *après* qu'un patient soit reparti sans traitement. Nabbahni déplace la détection en amont : prévoir la demande, estimer la couverture réelle, et déclencher une action avant l'incident.

Deux pertes sont traitées simultanément, car elles ont la même cause — une allocation faite sur des seuils fixes plutôt que sur la consommation réelle :

- **La rupture** : le stock manque là où la demande est.
- **La péremption** : le stock existe là où personne ne le consomme.



2. Vue d'ensemble



3. Stack technique

COUCHE	TECHNOLOGIES	RÔLE
Frontend	Next.js 15 (App Router), TypeScript, Tailwind, MapLibre GL, Recharts	3 portails, 6 rôles, fr/ar + RTL
Backend	FastAPI, SQLAlchemy 2, Pydantic v2	API REST, RBAC, audit
Données	PostgreSQL + PostGIS, Redis, RabbitMQ, MinIO	Persistance, cache, files, objets
ML	XGBoost, LightGBM, Prophet, SHAP, MLflow	Prévision, classification, explicabilité
Auth	Keycloak (OIDC, MFA)	6 rôles, MFA sur profils sensibles
Observabilité	Prometheus, Grafana, OpenTelemetry, Sentry	Métriques, traces, alertes

Portabilité du stockage. La couche de persistance est indépendante du dialecte : PostgreSQL + PostGIS en production, SQLite en local. Un `TypeDecorator` arbitre JSONB/JSON et UUID natif/CHAR(36) ; les requêtes géographiques ont un équivalent Python (haversine). Conséquence pratique : la plateforme démarre en 8 minutes sans Docker, ce qui a permis de la démontrer sur un poste sans infrastructure.

4. Modèle de données

Quatre familles de tables :

FAMILLE	TABLES PRINCIPALES
Référentiel	medications (ATC, DDD, prix, essentiel), governorates (géométrie), pharmacies, suppliers, users
Transactionnel	sales_daily, stock_levels, stock_batches, national_stock, import_orders, shipments
ML	forecasts, shortage_predictions, prediction_explanations, model_runs
Décision	recommendations, substitutions, alerts, audit_logs

Granularité des lots

La table `stock_batches` est ce qui rend la péremption calculable. Deux pharmacies détenant 1 000 boîtes sont dans des situations opposées si l'une a un lot qui expire le mois prochain et l'autre dans deux ans — un compteur de stock agrégé ne peut pas distinguer les deux.

5. Intelligence artificielle

5.1 Prévision de la demande

Un modèle global par horizon (7 / 14 / 30 / 90 jours) plutôt qu'un modèle par série : la grille médicament × gouvernorat est trop large pour un entraînement par série, et un modèle global partage l'information entre séries peu volumineuses.

16 features, toutes comportementales : lags (1, 7, 14, 28), moyennes et écarts-types glissants (7, 28, 90), jour de semaine, mois, week-end, indice grippal, prix unitaire, statut essentiel, variation de demande à 30 jours.

Correction de la censure. Un jour de rupture enregistre zéro vente — mais la demande n'était pas nulle, elle était insatisfaite. Sans correction, le modèle apprend que la rupture fait disparaître la demande et sous-estime systématiquement les réapprovisionnements. Les jours de rupture sont donc imputés par une moyenne glissante sur 14 jours.

HORIZON	CHAMPION	WAPE	MAPE
7 jours	LightGBM	6,0 %	7,7 %
14 jours	LightGBM	6,0 %	9,3 %
30 jours	LightGBM	6,1 %	8,6 %
90 jours	XGBoost	10,9 %	11,1 %

Champion sélectionné par WAPE en validation à origine glissante (3 plis). Les quantiles 0,1 / 0,5 / 0,9 fournissent les intervalles de confiance à 80 %.

5.2 Moteur de rupture

Classifieur binaire LightGBM : probabilité de rupture à 30 jours à partir de la couverture, la volatilité de demande, l'historique de rupture, les retards fournisseurs et l'indice grippal. La probabilité est convertie en 5 niveaux (vert → critique), avec une **règle de sécurité** qui force le niveau critique dès qu'un médicament essentiel passe sous 5 jours de couverture, quelle que soit la sortie du modèle.

Lecture honnête des métriques. L'AUC mesurée est de 0,999 — un chiffre qui n'arrive pas sur des données réelles. Le générateur synthétique fabrique les épisodes de rupture à partir des mêmes signaux que le classifieur reçoit, donc le problème est quasi séparable. Le pipeline est vérifiable de bout en bout ; la valeur prédictive réelle ne sera mesurable qu'après réentraînement sur les données de la PCT.

5.3 Explicabilité — aucune décision opaque

Chaque prédiction porte son explication SHAP, calculée *au moment du scoring* et persistée. Jamais dans le chemin de requête : une explication qui coûte une seconde à l'affichage n'est pas consultée, et une explication non consultée ne protège personne.

```
# Exemple réel, Efferalgan 500 – niveau critique
Couverture nationale faible (19 jours de stock) +9.579
Ruptures fréquentes récemment (46% des jours) +3.740
Demande volatile difficile à couvrir +0.661
La demande a augmenté de 38% sur 30 jours -0.559
Fournisseur en retard de 3 jours en moyenne +0.414
```

Les contributions sont rendues en français et en arabe, avec un graphe divergent signé (ce qui augmente le risque à droite, ce qui le réduit à gauche).

6. Moteur de péremption et d'allocation

6.1 Projection de perte (FEFO)

Pour chaque lot : la quantité détenue est comparée à ce que la pharmacie consommera avant la date de péremption. Le surplus est une perte projetée.

Rotation FEFO. Les lots s'écoulent par date de péremption croissante. Un lot ne reçoit donc que la consommation *restante* une fois les lots plus courts écoulés. Évalué indépendamment, chaque lot paraît sûr et la perte est massivement sous-estimée — c'est le point le plus subtil du module, et il est couvert par un test dédié.

6.2 Quantité nécessaire par pharmacie

Commander à un seuil fixe est précisément ce qui produit la péremption : une pharmacie qui vend 3 boîtes par mois n'a pas besoin de 200. L'allocation dimensionne chaque livraison sur la consommation observée :

```
cible          = consommation_journalière × (30 réappro + 14 délai + 10 sécurité)
stock_utile    = stock_total - quantité_qui_périmerait_invendue
à_commander    = max(0, cible - stock_utile)
```

La commande est calculée sur le stock **utilisable**, pas sur le compteur affiché. Compter du stock condamné comme disponible est exactement ce qui laisse une pharmacie sursstockée et en rupture au même moment.

6.3 Redistribution

Deux contraintes séparent une économie réelle d'une économie fictive :

- **Le lot doit survivre au trajet** : minimum 21 jours restants (7 de transport + 14 de vente). Déplacer un lot qui expire demain ne fait que relocaliser la perte.
- **Le destinataire doit l'écouler** : la quantité est plafonnée par ce qu'il vend réellement d'ici l'expiration.

Impact mesuré. Sans ces contraintes, le moteur proposait des transferts de stock expirant *le lendemain* et affichait 524 000 TND « sauvés ». Après correction : 39 transferts réalisables, **627 000 TND effectivement récupérables**.

6.4 Résultats sur le jeu de données

8,5 %

TAUX DE GASPILLAGE
PROJETÉ

30,5 M

TND À RISQUE

22,6 M

TND DÉJÀ PÉRIMÉS

627 k

TND RÉCUPÉRABLES

7. API

DOMAINE	ENDPOINTS	ACCÈS
Ruptures	GET /shortages, /{id}, /{id}/explanation, /map	PCT, régional, pharmacien
Stocks	GET /stock/national, /stock/analysis, /stock/pharmacy/{id}	PCT, régional
Péréemption	GET /expiry/analysis, /expiry/pharmacy/{id}, /expiry/redistribution	PCT, régional, pharmacien
Décision	GET /recommendations, POST /{id}/validate reject	PCT, régional
Citoyen	GET /citizen/availability, /pharmacies/nearby	public
Gouvernance	GET /admin/model-runs, /admin/audit-logs	PCT uniquement

OpenAPI complet exposé sur /docs. Cache Redis 60 s sur les agrégats coûteux, limitation de débit sur les routes publiques.

8. Sécurité et conformité

EXIGENCE	MISE EN ŒUVRE
Authentification	Keycloak OIDC, validation RS256 via JWKS, MFA sur PCT et autorités régionales
Autorisation	RBAC à 6 rôles, dépendance <code>require_roles()</code> par endpoint
Traçabilité	<code>audit_logs</code> en append-only, écrit par middleware sur tout appel mutant
Données personnelles	Aucune identité patient. Contact citoyen haché. Minimisation par conception (RGPD)
Chiffrement	TLS en transit, chiffrement au repos au niveau volume
OWASP Top 10	Cartographie documentée dans docs/security/owasp-mapping.md

Garde-fou de conception. Le point d'entrée de démonstration `/auth/dev-login` refuse activement de répondre dès que Keycloak est activé. Une commodité de développement qui survivrait en production serait un contournement d'authentification.

9. Qualité et vérification

- **28 tests** automatisés (24 backend dont 13 sur péréemption/allocation, 4 ML)
- Typage strict TypeScript, build Next.js sans avertissement (29 pages)
- CI GitHub Actions : ruff, pytest, eslint, tsc, Trivy, pip-audit, npm audit
- Modèles entraînés versionnés : un clone neuf est opérationnel en ~8 minutes

10. Limites connues

Énoncées explicitement plutôt que découvertes par un évaluateur :

- **Données synthétiques.** Les modèles sont entraînés sur un générateur, pas sur des ventes réelles. Les métriques ne sont pas des performances terrain.

- **Ventes agrégées par gouvernorat.** La consommation d'une pharmacie est estimée au prorata de sa part du stock régional, faute de remontée par comptoir.
- **Frontières administratives approximatives** (tessellation de Voronoï bornée par l'enveloppe convexe du pays).
- **Interface partiellement bilingue.** Le RTL arabe fonctionne ; les écrans les plus récents restent en français.
- **Connecteurs externes et couche LLM** conçus mais non raccordés à des flux réels.

Nabbahni — Documentation technique v1.0 · Juillet 2026 · Aide à la décision : un pharmacien ou un officier PCT valide toute action.